障害報告書

2026年10月20日、推論サーバーのメモリ不足により応答が停止した。

再発防止策

KV キャッシュの上限を設定し、監視アラートを追加する。